


# CLASIFICACIÓN DE OBJETOS

## Regresión Logística – Aprendizaje (I)


**Antonio M. López**

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN



$$\mathcal{C}_{\mathbf{w},T}(\mathbf{x}) = \begin{cases} 1 & \text{si } h_{\mathbf{w}}(\mathbf{x}) < T \sim \mathbf{w}^T \mathbf{x} < \ln\left(\frac{T}{1-T}\right) \\ 0 & \text{en otro caso} \end{cases}$$

Donde  $h_{\mathbf{w}}(\mathbf{x}) = \text{Logistic}(\mathbf{w}^T \mathbf{x}) = \frac{1}{1+e^{-\mathbf{w}^T \mathbf{x}}}$



- ¿Qué  $\mathbf{w}$  usar? ➔ Aprendizaje automático

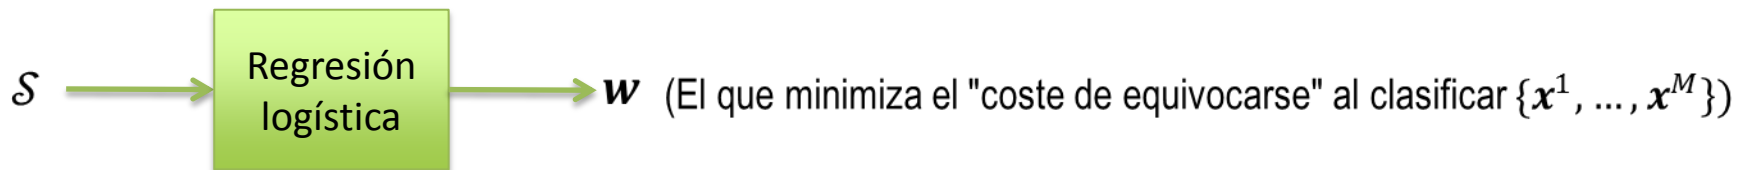
$\mathbf{w}$  se aprende a partir de un conjunto de muestras

Conjunto de entrenamiento:  $\mathcal{S} = \{(\mathbf{x}'^1, y^1), \dots, (\mathbf{x}'^M, y^M)\}$

$(\mathbf{x}'^j, y^j)$  j-ésima muestra de entrenamiento

$\mathbf{x}'^j \in \mathbb{R}^n \rightarrow$  Lo transformamos en  $\mathbf{x}^j \in \mathbb{R}^{n+1}$ , donde  $\mathbf{x}^j = (1, \mathbf{x}'^j)$

$y^j \in \{0, 1\}$  clasificación binaria y supervisada




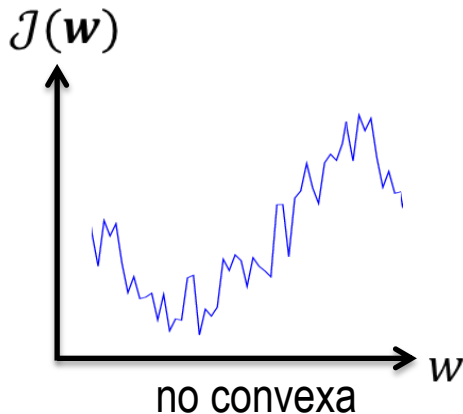
- El coste de equivocarse al clasificar  $\mathbf{x}^j$  se puede definir como  $(y^j - h_{\mathbf{w}}(\mathbf{x}^j))^2$ , es decir, utilizando la denominada pérdida cuadrática (*squared loss*,  $L_2$ ).
- El vector  $\mathbf{w}^*$  que minimiza el coste de equivocarse para  $S$  en su totalidad se podría obtener resolviendo:

$$\mathbf{w}^* \longleftarrow \underset{\mathbf{w} \in \mathbb{R}^{n+1}}{\operatorname{argmin}} \frac{1}{M} \sum_{j=1}^M (y^j - h_{\mathbf{w}}(\mathbf{x}^j))^2$$

$\mathcal{J}(\mathbf{w})$

Comentarios:

- No hay una solución cerrada fácil para obtener  $\mathbf{w}^*$ , es decir, no podemos "despejar"  $\mathbf{w}$  de una manera sencilla a partir de  $J(\mathbf{w})$ .
- Por tanto, se opta por utilizar un método de optimización que a partir de un valor inicial de  $\mathbf{w}$  y unas ecuaciones de "actualización", nos lleve a la solución que buscamos.
- Sin embargo,  $J(\mathbf{w})$  no es una función convexa respecto a  $\mathbf{w}$ . Por lo tanto, es difícil de optimizar (en este caso minimizar).




- Por ese motivo, se utiliza la siguiente alternativa:

$$(y^j - h_w(\mathbf{x}^j))^2 \longrightarrow \text{coste}(h_w(\mathbf{x}^j), y^j)$$

$$\text{coste}(\hat{y}, y) = \begin{cases} -\ln(\hat{y}) & \text{si } y = 1 \\ -\ln(1 - \hat{y}) & \text{si } y = 0 \end{cases}$$

$$\hat{y} \in [0, 1]$$




$$\bullet \text{coste}(\hat{y}, y) = \begin{cases} -\ln(\hat{y}) & \text{si } y = 1 \\ -\ln(1 - \hat{y}) & \text{si } y = 0 \end{cases}$$



compactado

$$-(y \ln(\hat{y}) + (1 - y) \ln(1 - \hat{y}))$$



$J(\mathbf{w})$  es convexa  
respecto  $\mathbf{w}$

$$J(\mathbf{w}) = -\frac{1}{M} \sum_{j=1}^M y^j \ln(h_{\mathbf{w}}(\mathbf{x}^j)) + (1 - y^j) \ln(1 - h_{\mathbf{w}}(\mathbf{x}^j))$$

Regresión  
logística

$$\mathbf{w}^* \leftarrow \underset{\mathbf{w} \in \mathbb{R}^{n+1}}{\operatorname{argmin}} J(\mathbf{w})$$

- Conceptos clave de este vídeo:
  - Conjunto de entrenamiento
  - Aprendizaje automático supervisado
  - Regresión logística
  - Función de coste