

# CLASIFICACIÓN DE OBJETOS


## Regresión Logística – Aprendizaje (III)

**Antonio M. López**

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

- Fronteras no lineales:

$$(x_1 - c_{x_1})^2 + (x_2 - c_{x_2})^2 = r^2$$




$$\mathbf{w} = (w_0, w_1, w_2, w_3, w_4, w_5)^T$$

$$\mathbf{x} = (1, x_1, x_2, x_1^2, x_1 x_2, x_2^2)^T$$

$$\mathbf{w} = ((c_{x_1}^2 + c_{x_2}^2 - r^2), -2c_{x_1}, -2c_{x_2}, 1, 0, 1)^T$$

- Sobreajuste (overfitting):

- Las muestras tienen ruido o son incompletas.
- El modelo de frontera es una aproximación.



- Aunque se consiga un clasificador sin error en la clasificación de las muestras de entrenamiento, esto no garantiza la correcta clasificación de muestras nuevas (capacidad de Generalización).
- El problema tiende a manifestarse especialmente cuando el número de parámetros del modelo es muy alto (dimensión alta del descriptor) respecto al número de muestras de entrenamiento.



- Aumentar el número de muestras de entrenamiento.
- Bajar dimensión del descriptor (selección de características).
- Selección del modelo.
- **Regularización del modelo.**

- Regularización de la Regresión Logística:

$$\mathcal{J}_R(\mathbf{w}) \leftarrow \mathcal{J}(\mathbf{w}) + \frac{\lambda}{2M} \sum_{i=1}^n w_i^2$$

Repetir (en paralelo)

$$w_0^{(k)} \leftarrow w_0^{(k-1)} - \frac{\alpha}{M} \sum_{j=1}^M (h_{\mathbf{w}}(\mathbf{x}^j) - y^j) x_0^j$$

$$\forall i \in \{1, \dots, n\}$$

$$w_i^{(k)} \leftarrow w_i^{(k-1)} - \frac{\alpha}{M} \left[ \sum_{j=1}^M (h_{\mathbf{w}}(\mathbf{x}^j) - y^j) x_i^j + \lambda w_i \right]$$

Hasta converger /\* p.e. monitorizar  $\mathcal{J}_R(\mathbf{w})$  \*/

$\lambda \in \mathbb{R}^+$ , determina el grado de penalización.

- Punto de vista de la Probabilidad:
$$P(Y=1|X=\mathbf{x}; \mathbf{w}) = h_{\mathbf{w}}(\mathbf{x}) = \text{Logistic}(\mathbf{w}^T \mathbf{x})$$
$$P(Y=0|X=\mathbf{x}; \mathbf{w}) = 1 - h_{\mathbf{w}}(\mathbf{x})$$
- Podemos usar un algoritmo tipo máxima verosimilitud (*likelihood*; ML) para aprender  $\mathbf{w}$ .
- En particular, queremos obtener el  $\mathbf{w}^*$  que maximice la verosimilitud de que el conjunto de muestras  $\mathcal{S} = \{(\mathbf{x}^1, y^1), \dots, (\mathbf{x}^M, y^M)\}$  fuese generado según  $P(Y|X; \mathbf{w})$   
➔ Máxima Verosimilitud Condicional (*Maximum Conditional Likelihood*).
- Esto se reduce a resolver el siguiente problema:

$$\mathcal{L}(\mathbf{w}) = \prod_{j=1}^M P(Y=y^j | X=\mathbf{x}^j; \mathbf{w})$$

Muestras *iid*:  
independientes  
idénticamente distribuidas

$$\mathbf{w}^* \longleftarrow \underset{\mathbf{w} \in \mathbb{R}^{n+1}}{\operatorname{argmax}} \mathcal{L}(\mathbf{w})$$

- Alternativamente:

$$\mathcal{L}(\mathbf{w}) = \ln \prod_{j=1}^M P(Y=y^j | X=\mathbf{x}^j; \mathbf{w}) = \sum_{j=1}^M \ln P(Y=y^j | X=\mathbf{x}^j; \mathbf{w})$$

$$\mathbf{w}^* \longleftarrow \underset{\mathbf{w} \in \mathbb{R}^{n+1}}{\operatorname{argmax}} \mathcal{L}(\mathbf{w})$$



$$\mathcal{J}(\mathbf{w}) = - \sum_{j=1}^M \ln P(Y=y^j | X=\mathbf{x}^j; \mathbf{w}) = - \sum_{j=1}^M y^j \ln(h_{\mathbf{w}}(\mathbf{x}^j)) + (1 - y^j) \ln(1 - h_{\mathbf{w}}(\mathbf{x}^j))$$

$$\mathbf{w}^* \longleftarrow \underset{\mathbf{w} \in \mathbb{R}^{n+1}}{\operatorname{argmin}} \mathcal{J}(\mathbf{w})$$

- Con regularización:

$$\mathcal{L}(\mathbf{w}) = \sum_{j=1}^M \ln P(Y=y^j | X=\mathbf{x}^j; \mathbf{w}) - \frac{\lambda}{2} \|\mathbf{w}\|^2$$
$$\mathbf{w}^* \longleftarrow \underset{\mathbf{w} \in \mathbb{R}^{n+1}}{\operatorname{argmax}} \mathcal{L}(\mathbf{w})$$

- Es interesante recordar que en una estimación de  $\mathbf{w}$  tipo MAP (máximo a posteriori), la expresión a optimizar en este caso tendría la forma:

$$\sum_{j=1}^M \ln P(Y=y^j | X=\mathbf{x}^j; \mathbf{w}) + \ln P(\mathbf{w})$$

y si  $P(\mathbf{w})$  es una Gaussiana centrada en cero con varianza proporcional a  $1/\lambda$ , entonces  $\ln P(\mathbf{w})$  es proporcional a  $-\lambda \|\mathbf{w}\|^2 \rightarrow$  la versión regularizada es tipo MAP.

- Múltiples clases ( $K$ ): Uno-contra-todos (“one-vs-all”)

→ una regresión logística por clase, los  $\{w_1, \dots, w_K\}$  se aprenden por separado

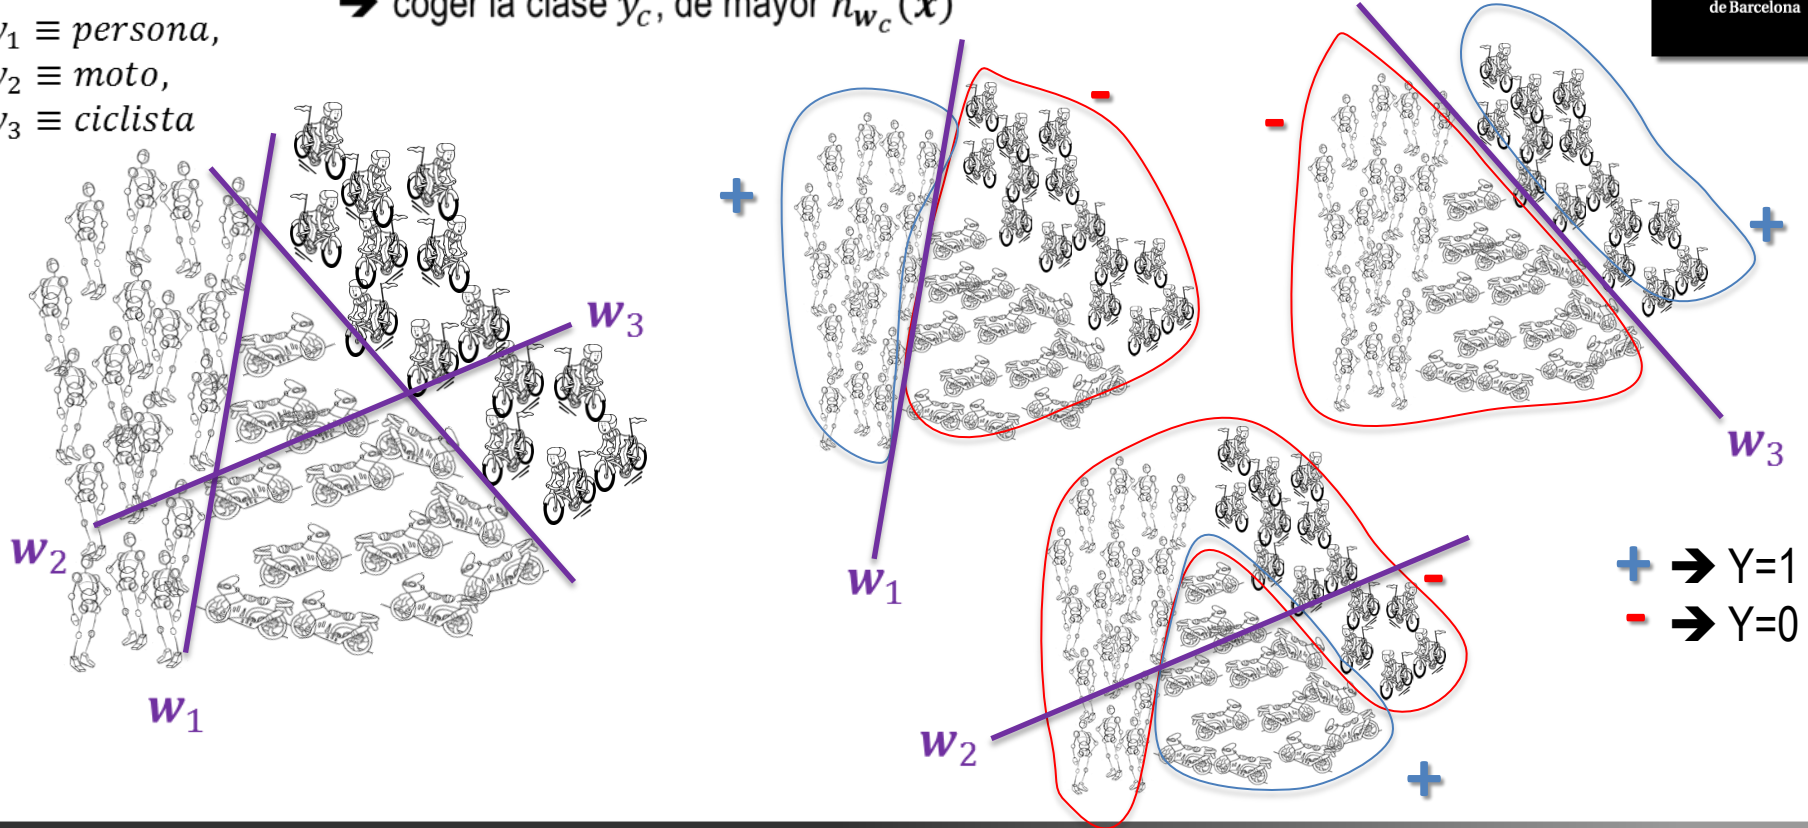
→ coger la clase  $y_c$ , de mayor  $h_{w_c}(x)$

$K=3$

$y_1 \equiv \text{persona}$ ,

$y_2 \equiv \text{moto}$ ,

$y_3 \equiv \text{ciclista}$





- Múltiples clases ( $K$ ): Regresión Logística Multinómica (*multinomial logit*)


→ Los  $\{\mathbf{w}_1, \dots, \mathbf{w}_K\}$  se aprenden simultáneamente.

$K=3$

$y_1 \equiv \text{persona,}$

$y_2 \equiv \text{moto,}$

$y_3 \equiv \text{ciclista}$



$$\mathbf{W} = \{\mathbf{w}_1, \dots, \mathbf{w}_K\}$$

$$P(Y=y_K | X=\mathbf{x}; \mathbf{W}) = \frac{1}{1 + \sum_{j=1}^{K-1} e^{\mathbf{w}_j^\top \mathbf{x}}}$$

$$\forall c \in \{1, \dots, K-1\}$$

$$P(Y=y_c | X=\mathbf{x}; \mathbf{W}) = \frac{e^{\mathbf{w}_c^\top \mathbf{x}}}{1 + \sum_{j=1}^{K-1} e^{\mathbf{w}_j^\top \mathbf{x}}}$$

- Conceptos clave de este vídeo:
  - Fronteras no lineales.
  - Problema del sobreajuste.
  - Regularización en regresión logística.
  - ML, MAP en regresión logística.
  - Multiclase en regresión logística.